

Ғылыми-практикалық презентация

Марков шешім үдерістері және нығайтпалы оқыту

Reinforcement Learning & Markov Decision Processes (MDP)

Зерттеудің негізгі мақсаты

Белгісіз әрі динамикалық ортада автономды ИИ Агенттің оңтайлы шешім қабылдау логикасын зерттеу. Оқыту процесі сыйақы алу (Reward) мен қателіктерді азайту (Trial & Error) механикасына негізделген.

Автономды Агент

Секундына миллиондаған математикалық сценарийлерді талдайтын интеллектуалды модель.

Оңтайлы Саясат

Беллман рекурсиясы арқылы ең максималды жиынтық сыйақыға жеткізетін траектория.

01 // Нығайтпалы оқытудың практикалық ортасы

Нығайтпалы оқыту (Reinforcement Learning) алгоритмдері күрделі ойын жүйелерінен бастап шынайы өндірістік робототехникаға дейін кеңінен қолданылады:



Шахмат пен Стратегия

Агент миллиондаған жүріс комбинацияларын алдын ала есептеп, оңтайлы шахматтық партияны құрастырады (мысалы, AlphaZero).



Автономды жарыс

Көліктердің кедергілерді айналып өтіп, максималды қауіпсіз жылдамдықты сақтауын қамтамасыз ететін пилотсыз симуляторлар.



Робототехника

Робот-манипуляторлардың микро-қозғалыстарын дәл баптап, физикалық нысандарды ұстау мен орналастыруды үйрету.



Лабиринттер мен Квесттер


Агенттің 2D/3D виртуалды лабиринттерден ең қысқа жолмен шығып, бонус ұпайларын жинау симуляциясы.



Барлық салалардың ортақ кілті: **Агент + Интерактивті орта + Сыйақы сигналы**

02 // Агент пен Орта арасындағы тұйық цикл (RL Loop)

Нығайтпалы оқыту жүйесі Агент (Agent) пен Ортаның (Environment) үздіксіз ақпарат алмасуына негізделген:



🔄 Цикл компоненттерінің анықтамасы

- **Әрекет (Action, A_t):** Агенттің ағымдағы мезетте ортаға жасайтын қозғалысы (мысалы: алға жүру, бұрылу).
- **Сыйақы (Reward, R_t):** Ортаның жасалған әрекетке беретін оң немесе теріс сан түріндегі бағасы (+10 немесе -5).
- **Ағымдағы күй (State, S_{t+1}):** Әрекеттен кейінгі Агенттің ортадағы жаңа позициясы мен жағдайы.

03 // MDP-нің 5 Негізгі Элементі $M = (S, A, P, R, \gamma)$

Марков шешім үдерісі (MDP) барлық нығайтпалы оқыту есептерін математикалық түрде сипаттауға арналған 5 элементтен тұрады:

[S] State — Күйлер жиынтығы

БАСТАПҚЫ ОРЫН

Агенттің ортадағы барлық мүмкін орналасу параметрлері мен жағдайлары.

[A] Action — Әрекеттер жиынтығы

БАСҚАРУ

Агенттің әрбір күйде орындай алатын қолжетімді барлық жүрістері.

[P] Transition Probability — Өту ықтималдығы

 $P(s' | s, a)$

s күйінде a әрекетін жасағанда s' жаңа күйіне ауысудың ықтималдығы.

[R] Reward Function — Сыйақы функциясы

БАҒАЛАУ

Орта тарапынан берілетін лездік сыйақы мөлшері $R(s, a, s')$.

γ] Discount Factor — Дисконт факторы ($0 \leq \gamma < 1$)

БОЛАШАҚ

Болашақта алынатын сыйақының ағымдағы мезеттегі құнсыздану коэффициенті.

04 // Марков Қасиеті (Markov Property)

Марков үдерісінің негізгі гипотезасы: «Болашақ өткенге тәуелсіз, ол тек ағымдағы күйге байланысты».

МАРКОВ ШАРТТЫ ЫҚТИМАЛДЫҒЫ

$$P(S_{t+1} | S_t, A_t, S_{t-1}, A_{t-1}, \dots) = P(S_{t+1} | S_t, A_t)$$

Болашақ S_{t+1} күйі тек ағымдағы S_t күйі мен A_t әрекетіне байланысты.

❌ Өткен Тарих Өшеді

Агенттің бұған дейін қандай жолдардан өткені ($S_0, S_1, \dots, S_{t-1}$) болашақ шешімдерге ешқандай әсер етпейді.


✅ Ағымдағы Күй Жеткілікті

S_t ағымдағы күйі алдағы қадамды дұрыс жоспарлау үшін барлық қажетті толық ақпаратты өз ішінде сақтайды.

🔥 **Практикалық маңызы:** Жад көлемін үнемдейді және есептеу күрделілігін шексіз тармақталудан сақтайды.

05 // Шешімдер ағашы және $V(s)$ Күй құндылығы

Агент әрбір жүрісті жасамас бұрын мүмкін болатын болашақ сценарийлер тармағын талдайды:



КҮТІЛЕТІН СУММАРЛЫҚ ДИСКОНТТАЛҒАН СЫЙАҚЫ

$$V(s) = \mathbb{E} [R_{t+1} + \gamma R_{t+2} + \gamma^2 R_3 + \dots | S_t = s]$$

💡 $V(s)$ Ценность (Құндылық) Мәні

Күйдің құндылығы $V(s)$ — Агенттің осы s күйінен бастап ойынның соңына дейін жинай алатын барлық дисконтталған сыйақыларының орташа математикалық күтімі.

06 // Беллманның Оңтайлы Теңдеуі (Bellman Equation)

Нығайтпалы оқытудың ең негізгі теңдеуі — ағымдағы күй құндылығын келесі күйлердің құндылығы арқылы рекурсивті түрде өрнектейді:

BELLMAN OPTIMALITY EQUATION

$$V^*(s) = \max_a \sum_{s'} P(s' | s, a) \cdot [R(s, a, s') + \gamma \cdot V^*(s')]$$

$\max_a$

Мүмкін болатын барлық әрекеттердің ішінен ең жоғары пайда беретінін таңдау.

$P(s' | s, a)$

Әрекет жасалғаннан кейінгі келесі s' күйіне ауысудың ықтималдығы.

$R(s, a, s')$

Осы қадамда қолға түсетін нақты лездік сыйақы мөлшері.

$\gamma \cdot V^*(s')$

Келесі s' күйінің дисконтталған оңтайлы келешек құндылығы.

07 // Оңтайлы саясат (π^*) және Model-Free RL

Беллман рекурсиясын шешу арқылы Агент өзінің ең жоғарғы рекордына жеткізетін стратегияны табады:

🎯 Оңтайлы Саясат (Optimal Policy, π^*)

Беллман теңдеуінің шешімі ретінде әрбір күйде қандай әрекет орындау керектігін көрсететін ең үздік ережелер жиынтығы: $\pi^*(s) = \operatorname{argmax}_a Q^*(s, a)$.

🔍 Үлгісіз Оқыту (Model-Free RL & Q-Learning)

Егер ортаның картасы мен өту ықтималдығы $P(s'|s,a)$ белгісіз болса, Агент «Сынақ пен Қателік» (Trial & Error) әдісі арқылы тәжірибе жинап, өзін-өзі оқытады.

✓ ҚОРЫТЫНДЫ

Марков шешім үдерістері — Жасанды Интеллектке белгісіздік жағдайында оңтайлы шешім қабылдауға мүмкіндік беретін математикалық іргетас!