ПРАКТИКАЛЫҚ ЖҰМЫС 5

Марков шешім қабылдау процестері және мәндер итерациясы

Негізгі идея

Сіз жеткізу роботына әрекеттің нәтижесі белгісіз болған жағдайда әрекетті қалай таңдау керектігін үйретесіз. Алдымен шағын мысалды қолмен шешіп, содан кейін дәл осы идеяны Python тілінде жүзеге асырасыз.

1. Оқу мақсаттары

Осы практикалық жұмыстың соңында сіз:

- кейбір ЖИ есептерінің неліктен детерминделмеген болатынын түсіндіре аласыз;
- MDP-дің күйлерін, әрекеттерін, ауысу ықтималдықтарын, марапаттарын, бастапқы күйін және терминалдық күйлерін анықтай аласыз;
- саясатты агентке әр күйде қандай әрекет жасау керектігін көрсететін ереже ретінде түсіндіре аласыз;
- дисконтталған марапаттар тізбегін есептей аласыз;
- қарапайым Q-мәндері мен күй мәндерін есептей аласыз;
- мәндер итерациясының бірнеше қадамын қолмен орындай аласыз;
- Python тілінде шағын мәндер итерациясы алгоритмін жүзеге асыра аласыз;
- белгісіздік, марапаттар және дисконттау коэффициенті агенттің мінез-құлқына қалай әсер ететінін түсіндіре аласыз.

2. Жұмысты бастамас бұрын: есептің шарты

Шағын қойма ішінде жұмыс істейтін автономды жеткізу роботын елестетіңіз. Робот S күйінен бастайды және G жеткізу нүктесіне жетуі керек. Бір ұяшық қауіпті (X), ал бір ұяшық қабырғамен (#) жабылған.

A	B	C	**G +10**
D	#	E	**X -10**
S	F	H	I

Робот төрт әрекеттің бірін таңдай алады: UP, DOWN, LEFT, RIGHT. Алайда робот әрқашан жоспарланған бағытта дәл қозғала бермейді.

Маңызды

Қарапайым детерминдік іздеуде әрекеттің бір белгілі нәтижесі болады. MDP-де бір әрекеттің әрқайсысының өз ықтималдығы бар бірнеше мүмкін нәтижесі болуы мүмкін.

3. Негізгі ұғымдар өте қарапайым тілмен

Термин	Мағынасы
Күй (s)	Агенттің ағымдағы жағдайы. Мұнда күй — робот тұрған ұяшық, мысалы S, F, H немесе C.
Әрекет (a)	Агент жасайтын таңдау, мысалы UP, DOWN, LEFT немесе RIGHT.
Ауысу T(s, a, s')	s күйінде a әрекетін орындағанда келесі s' күйіне өту ықтималдығы.
Марапат R	Нәтиженің жақсы немесе жаман екенін агентке көрсететін сан. Оң мән = қалаулы; теріс мән = қалаусыз.
Саясат π(s)	Әр күй үшін әрекетті анықтайтын ереже. Мысал: π(F) = RIGHT дегеніміз робот F күйінде болса, RIGHT әрекетін орындау керек дегенді білдіреді.
Терминалдық күй	Эпизод аяқталатын күй. Бұл жұмыста G және X — терминалдық күйлер.
Мән V(s)	Агент осы күйден бастап дұрыс әрекет етсе, s күйінде болудың қаншалықты жақсы екенін көрсетеді.
Q-мәні Q(s,a)	s күйінде a әрекетін орындап, кейін дұрыс әрекет етудің қаншалықты жақсы екенін көрсетеді.
Дисконттау коэффициенті γ	0 мен 1 арасындағы сан; ол агенттің болашақ марапаттарды қаншалықты маңызды деп есептейтінін басқарады.

4. 1-тапсырма – MDP-ді анықтау

Жеткізу роботы үшін MDP сипаттамасын толықтырыңыз.

1. Күйлер S: робот орналаса алатын барлық ұяшықтарды жазыңыз. Қабырғаны қоспаңыз.

2. Әрекеттер A: барлық мүмкін қозғалыс әрекеттерін жазыңыз.

3. Бастапқы күй s_0: робот қай жерден бастайтынын анықтаңыз.

4. Терминалдық күйлер: эпизод қай жерде аяқталатынын анықтаңыз.

5. Марапаттар: G-ге жеткенде +10, X-ке жеткенде −10 және әрбір қалыпты қозғалыс үшін −0.1 пайдаланыңыз.

Жауабыңызды жазыңыз:

Күйлер	A, B, C, D, E, S, F, H, I, G, X
Әрекеттер	UP, DOWN, LEFT, RIGHT
Бастапқы күй	S

Терминалдық күйлер	G және X
Марапаттар	G-ге жеткенде +10, X-ке жеткенде −10, әрбір қалыпты қозғалыс үшін −0.1

5. 2-тапсырма – Белгісіздікті қосу

Дәрістегідей ықтималды қозғалыс моделін қолданамыз:

- 80% (0.8): робот таңдалған негізгі бағытта қозғалады.
- 10% (0.1): робот сол жаққа ауытқиды.
- 10% (0.1): робот оң жаққа ауытқиды.
- Егер алынған бағыт қабырғаға немесе тордың шетіне тірелсе, робот сол күйде қалады.

Мысал: робот H күйінде және UP әрекетін таңдайды. UP → E, LEFT → F, ал RIGHT → I.

Ағымдағы күй	Әрекет	Келесі күй	Ықтималдық
H	UP	E	0.8
H	UP	F	0.1
H	UP	I	0.1

Тексеру: 0.8 + 0.1 + 0.1 = 1.0. Бір әрекет үшін барлық ауысу ықтималдықтарының қосындысы 1-ге тең болуы керек.

Студенттің жұмысы: келесі жағдайлар үшін ауысу кестесін құрыңыз:

- F күйі, RIGHT әрекеті
- E күйі, RIGHT әрекеті
- C күйі, RIGHT әрекеті

Ағымдағы күй	Әрекет	Келесі күй	Ықтималдық
F	RIGHT	H	0.8
F	RIGHT	F	0.1
F	RIGHT	F	0.1

Ағымдағы күй	Әрекет	Келесі күй	Ықтималдық
E	RIGHT	X	0.8
E	RIGHT	C	0.1
E	RIGHT	H	0.1

Ағымдағы күй	Әрекет	Келесі күй	Ықтималдық
C	RIGHT	G	0.8
C	RIGHT	C	0.1
C	RIGHT	E	0.1

6. 3-тапсырма – Марапаттар мен дисконттауды түсіну

Агент әдетте жалпы марапатты барынша арттыруға тырысады. Бірақ жақын уақытта алынған марапат дәл сондай, бірақ әлдеқайда кейін алынатын марапаттан құндырақ болуы мүмкін. Мұны γ (гамма) дисконттау коэффициенті арқылы модельдейміз.

Дисконтталған пайдалылық:

$$U = r_0 + \gamma r_1 + \gamma^2 r_2 + \gamma^3 r_3 + \dots$$

Мысал. Марапаттар [1, 2, 3], ал γ = 0.5:

$U = 1 + 0.5 \times 2 + 0.5^2 \times 3 = 1 + 1 + 0.75 = 2.75$

γ қалай түсіндіріледі
γ 0-ге жақын → агент жақын уақыттағы марапаттарға көбірек көңіл бөледі. γ 1-ге жақын → болашақ марапаттар маңызды болып қала береді.

Есептеңіз:

Марапаттар тізбегі	γ	Сіздің есебіңіз	Пайдалылық
[2, 4, 6]	0.5	$2 + 0.5\times4 + (0.5^2)\times6 = 2 + 2 + 1.5$	5.5
[2, 4, 6]	0.9	$2 + 0.9\times4 + (0.9^2)\times6 = 2 + 3.6 + 4.86$	10.46
[0, 0, 10]	0.5	$0 + 0.5\times0 + (0.5^2)\times10 = 0 + 0 + 2.5$	2.5

7. 4-тапсырма – Q(s,a) және V(s) есептеу

Енді екі сұрақ қоямыз:

- Q(s,a): Егер осы әрекетті қазір орындасам, күтілетін нәтиже қаншалықты жақсы?
- V(s): Осы күйден алуға болатын ең жақсы күтілетін мән қандай?

$$Q(s,a) = \Sigma\, T(s,a,s')\, [\, R(s,a,s') + \gamma V(s')\,]$$

$$V(s) = \max_a Q(s,a)$$

Белгілерден қорықпаңыз. Бірінші формуланы былай оқыңыз:

Формуланы сөзбен
Әрбір мүмкін келесі күй үшін: ықтималдық × (дереу марапат + келесі күйдің дисконтталған мәні). Барлық нәтижелерді қосыңыз.

Шешілген мысал. Робот H күйінде және UP әрекетін таңдайды делік. γ = 0.9. V(E)=5, V(F)=2, V(I)=1, ал қозғалыс марапаты −0.1 деп алайық.

Q(H,UP) = 0.8[−0.1 + 0.9(5)] + 0.1[−0.1 + 0.9(2)] + 0.1[−0.1 + 0.9(1)]

= 0.8(4.4) + 0.1(1.7) + 0.1(0.8) = 3.52 + 0.17 + 0.08 = 3.77

Егер басқа әрекеттердің мәндері Q(H,LEFT)=2.1, Q(H,RIGHT)=1.8, Q(H,DOWN)=2.4 болса, онда V(H)=3.77 және ең жақсы әрекет — UP.

$$\mathbf{Q(s,a) = \Sigma\, T(s,a,s')\,[\,R(s,a,s') + \gamma V(s')\,]}$$

Q(C, RIGHT) = 0.8 × [10 + (0.9 × 0)] + 0.1 × [-0.1 + (0.9 × 0)] + 0.1 × [-0.1 + (0.9 × 0)] = 7.98

8. 5-тапсырма – Мәндер итерациясын қолмен орындау

Мәндер итерациясы әр күйдің бағаланған мәнін қайталап жақсартады.

1-қадам. Барлық терминалдық емес күйлер үшін $V_0(s)=0$ мәнінен бастаңыз.

2-қадам. Жаңа мәндерді есептеу үшін Беллман жаңарту формуласын қолданыңыз.

$$\mathbf{V_{k+1}(s) = \max_a \Sigma\, T(s,a,s')[R(s,a,s') + \gamma V_k(s')]}$$

3-қадам. Қайталаңыз. Мәндер жақсы және жаман терминалдық күйлерден тор бойымен біртіндеп таралады.

4-қадам. Мәндер өте аз ғана өзгерген кезде тоқтаңыз.

Негізгі идея
k+1 итерациясында әрқашан k итерациясындағы ЕСКІ мәндерді пайдаланыңыз. Жаңа есептелген мәндерді сол итерацияның ішінде араластырмаңыз.

γ = 0.9 қолданыңыз. C, E, H және I күйлері үшін V_1 және V_2 мәндерін есептеңіз. Оқытушы есептелетін әрекеттерді тағайындай алады.

Күй	$\mathbf{V_0}$	$\mathbf{V_1}$	$\mathbf{V_2}$
C	0	7.98	8.689

E	0	-0.1	4.646
H	0	-0.1	-0.19
I	0	-0.1	-0.19

9. Мәндерден саясатқа

Мәндер тұрақталғаннан кейін әрбір терминалдық емес күйде Q-мәні ең үлкен әрекетті таңдаңыз.

Осылайша π(s) саясаты алынады. Саясат — бір ғана бекітілген маршрут емес. Ол әр күйде не істеу керектігін көрсететін ереже.

Күй	Ең жақсы әрекет	Саясат белгіленуі
H	UP	π(H)=UP
F	RIGHT	π(F)=RIGHT
C	RIGHT	π(C)=RIGHT

10. 6-тапсырма — Python-да жүзеге асыру

Енді осы логиканы Python тілінде жүзеге асырасыз. Мақсат — графикалық ойын жасау емес. Мақсат — мәндер итерациясы циклінің қалай жұмыс істейтінін түсіну.

```
states = ["A", "B", "C", "D", "E", "S", "F", "H", "I"]
actions = ["UP", "DOWN", "LEFT", "RIGHT"]

gamma = 0.9
theta = 0.001

# Бастапқы мәндер
V = {s: 0.0 for s in states}

# transitions(s, a) функциясы тізім қайтаруы керек:
# [(ықтималдық, келесі_күй, марапат), ...]
# Мысал:
# [(0.8, "E", -0.1), (0.1, "F", -0.1), (0.1, "I", -0.1)]

while True:
    delta = 0
    new_V = V.copy()

    for s in states:
        q_values = []

        for a in actions:
            q = 0

            for prob, next_state, reward in transitions(s, a):
                next_value = V.get(next_state, 0)
                q += prob * (reward + gamma * next_value)

            q_values.append(q)
```

```
            new_V[s] = max(q_values)
            delta = max(delta, abs(new_V[s] - V[s]))

        V = new_V

        if delta < theta:
            break

print(V)
```

Сіздің тапсырмаларыңыз:

1. Тор үшін transitions(s, a) функциясын құрыңыз.
2. Мәндер итерациясын іске қосыңыз.
3. Әр күйдің соңғы мәнін экранға шығарыңыз.
4. Әр күй үшін әр әрекеттің Q-мәнін есептеп, Q-мәні ең үлкен әрекетті экранға шығарыңыз.
5. Соңғы саясатты UP, DOWN, LEFT және RIGHT арқылы (немесе бағыт көрсеткіштерімен) көрсетіңіз.

Күйлердің соңғы мәндері: A = 7.27 B = 8.19 C = 9.20 D = 6.42 E = 6.22 S = 5.62 F = 5.25 H = 4.88 I = 3.39
Соңғы саясат: A -> RIGHT B -> RIGHT C -> RIGHT D -> UP E -> UP S -> UP F -> RIGHT H -> LEFT I -> LEFT

11. 7-тапсырма — Эксперимент жасаңыз және түсіндіріңіз

Бағдарламаны әртүрлі параметрлермен бірнеше рет іске қосыңыз. Қандай өзгерістер болғанын жазыңыз.

Эксперимент	Өзгеріс	Саясат қалай өзгерді?	Неліктен?
1	γ: 0.9 → 0.2	Робот мақсатқа жетудің орнына сол орнында (немесе қабырғаға соғылып) қала беруді таңдады.	Дисконттау коэффициенті азайғанда, робот болашақтағы үлкен марапатты елемей, тек қазіргі жағдайын ойлады.
2	Негізгі бағыттағы қозғалыс: 0.8 → 0.6	Робот X қауіпті аймағына жақындамау үшін өте ұзақ, бірақ қауіпсіз маршрутты таңдады.	Қозғалыстағы ауытқу (белгісіздік) көбейгендіктен, робот кездейсоқ X-ке түсіп кетуден қатты қорықты.
3	Қауіпті күй марапаты: −10 → −30	Робот жоғарыдағы жолды (E арқылы) тастап, мақсатқа ең төменгі, қауіпсіздеу жолмен баруды жөн көрді.	Қауіпті аймақ үшін айыппұл ұлғайғанда, роботқа X күйіне түсу қаупі әлдеқайда тиімсіз болды..

4	Қалыпты қозғалыс марапаты: −0.1 → −1	Робот қауіпке қарамай, мақсатқа ең қысқа маршрутпен өте жылдам жетуге тырысты.	Әр қадам жасаған сайын алынатын айыппұл тым көп болғандықтан, робот ұзақ жүруді тиімсіз деп тапты..

Қарапайым сөйлемдермен жауап беріңіз. Мысал: «Қауіпті аймақ үшін айыппұл ұлғайғанда, робот қауіпсіздеу маршрутты таңдады, себебі X күйіне түсу әлдеқайда тиімсіз болды.»

12. Тапсыру қажет материалдар

- Толтырылған MDP сипаттамасы.
- 2-тапсырмадағы ауысу ықтималдықтарының кестелері.
- 3-тапсырмадағы дисконттау есептеулері.
- Кемінде бір толық Q-мәнін есептеу.
- V_0, V_1 және V_2 кестесі.
- Python бастапқы коды.
- Күйлердің соңғы мәндері және соңғы саясат.
- Эксперименттерден не үйренгеніңізді түсіндіретін қысқаша қорытынды (5–8 сөйлем).

13. Өзін-өзі тексеру сұрақтары

1. Детерминдік және стохастикалық қозғалыстың айырмашылығы неде?

Детерминдік қозғалыста әрекеттің тек бір ғана нақты нәтижесі болады. Ал стохастикалық қозғалыста әрекет белгісіздікпен орындалады, яғни бір әрекеттің әрқайсысының өз ықтималдығы бар бірнеше ықтимал нәтижесі болуы мүмкін.

2. T(s,a,s′) нені білдіреді?

Бұл ауысу ықтималдығы: агент s күйінде тұрып a әрекетін орындаған кезде, оның келесі s' күйіне өту ықтималдығын білдіреді.

3. Неліктен бір әрекет үшін ауысу ықтималдықтарының қосындысы 1-ге тең болуы керек?

Өйткені бұл бір әрекеттің барлық мүмкін болатын нәтижелерінің толық жиынтығын (100%) көрсетеді. Робот міндетті түрде бір жерге түсуі немесе орнында қалуы керек.

4. Марапат дегеніміз не?

Бұл нәтиженің немесе күйдің жақсы немесе жаман екенін агентке білдіретін сан (оң мән = қалаулы, теріс мән = қалаусыз).

5. V(s) және Q(s,a) арасындағы айырмашылық қандай?

V(s) — күй мәні, яғни агент осы күйден бастап дұрыс әрекет етсе, сол күйде болудың қаншалықты жақсы екенін көрсетеді. Ал Q(s,a) — әрекет мәні, яғни агент s күйінде нақты бір a әрекетін орындап, одан кейін дұрыс әрекет еткенде қандай нәтиже алатынын көрсетеді.

6. γ нені басқарады?

Гамма (γ) — дисконттау коэффициенті. Ол агенттің болашақ марапаттарды қаншалықты маңызды деп есептейтінін басқарады. Ол 0-ге жақын болса қазіргі марапатқа, ал 1-ге жақын болса болашаққа мән береді.

7. Саясат агентке нені көрсетеді?

Саясат (Policy) — агентке әрбір күйде қандай нақты әрекетті таңдау керектігін көрсететін ереже.

8. Неліктен мәндер итерациясын қайталаймыз?

Бастапқыда барлық күйлердің мәні белгісіз (нөл) болады. Мәндер терминалдық күйлерден (мақсаттан) бастап басқа күйлерге тор бойымен біртіндеп таралуы үшін және күйлердің бағаланған мәні тұрақталғанша оны қайталаймыз

9. Неліктен V_{k+1} жартылай жаңартылған мәндерден емес, V_k мәндерінен есептелуі керек?

Мәндердің біркелкі әрі қатесіз таралуын қамтамасыз ету үшін. Бір итерация ішінде тек алдыңғы қадамдағы ескі мәндерді қолдану керек, әйтпесе жаңа есептелген мәндер араласып, есептеу бұзылады.

10. Үлкенірек теріс марапат саясатты қалай өзгерте алады?

Теріс марапат (айыппұл) ұлғайған сайын, агент сол қауіпті аймаққа түсуден барынша қашады және тәуекелге бармай, қауіпсізірек маршрутты таңдайтын болады.

14. Қысқаша қорытынды

MDP әрекеттердің нәтижелері белгісіз болуы мүмкін жағдайларда шешім қабылдауды сипаттайды. Ол күйлерден, әрекеттерден, ауысу ықтималдықтарынан, марапаттардан және әдетте бастапқы күй мен терминалдық күйлерден тұрады. Саясат агентке әр күйде қандай әрекетті таңдау керектігін көрсетеді. V(s) мәні күйдің қаншалықты пайдалы екенін, ал Q(s,a) белгілі бір әрекетті орындаудың күтілетін пайдалылығын сипаттайды. Мәндер итерациясы күй мәндерін тұрақталғанға дейін қайта-қайта жаңартады. Соңғы мәндерді оңтайлы саясатты таңдау үшін пайдалануға болады.